Reglas de asociación sobre transacciones de retail: apriori frente a fp-growth

Sara Albarracín

Laboratorio 03 — 16 de octubre de 2026

1. Introducción

Se analizan las facturas de una tienda de conveniencia con dos objetivos: describir el comportamiento de compra y comparar dos implementaciones que resuelven el mismo problema, apriori y fp-growth. El conjunto son 13 archivos DBF de Visual FoxPro, uno por día, con 147.411 renglones que se agrupan en 68.807 facturas sobre 1.265 productos. El dato que condiciona todo es el tamaño de la canasta: 2,14 renglones por factura y 28,203 (41.0%) de facturas con un solo producto. Una canasta tan corta obliga a soportes mínimos muy bajos, y es ahí donde las dos implementaciones dejan de costar lo mismo.

2. Datos y método

El enunciado describe texto con una línea por factura; los archivos son DBF con una línea por *line-item*, así que la factura se reconstruye agrupando por archivo, caja, tipo de documento y consecutivo. La descripción del producto es un `Varchar` de FoxPro, cuyo último byte guarda la longitud: sin interpretarlo cada nombre arrastra un carácter de basura, y por eso el lector es propio y no `dbfread`. El procesamiento es un ETL de tres capas con 18 contratos de datos. Los nombres se canonizan por código, porque 23 códigos tienen más de una descripción y de otro modo el mismo producto repartiría su soporte entre dos ítems.

Los DBF **no traen hora**. La fecha sale del nombre del archivo; la hora se estima repartiendo las facturas de cada caja, en su orden real de facturación, sobre una jornada supuesta de 07:00 a 22:00: sirve para la posición dentro del día, no para horas absolutas. Se incluyen los cinco tipos de documento, y conviene saber que los que no son ventas son el 2 % de los documentos y el 55 % del valor —hay un inventario de cerveza por $13,9 millones repetido en cinco fechas—. Por eso se cita ticket *mediano* ($5,189) y no promedio ($14,468).

3. Resultados

La demanda está muy concentrada: las empanadas aparecen en una de cada diez facturas, el segundo producto del ranking ya baja al 41 % de ese volumen y el décimo no llega al 22 %. El ranking completo está en `outputs/tables/06_top10.csv`.

Los 13 archivos cubren dos semanas desiguales; solo el tramo del 9 al 15 de marzo trae los siete días una vez cada uno, y es el único donde comparar días es limpio. Sobre ese panel de 46,554 facturas, el índice es el valor del día sobre el promedio semanal.

Día	Facturas	Índice	Δ%	Canasta
lunes	5,978	0,899	-10,1	2,08
martes	6,551	0,985	-1,5	2,10
miercoles	7,151	1,075	7,5	2,08
jueves	7,737	1,163	16,3	2,10
viernes	8,477	1,275	27,5	2,09
sabado	5,239	0,788	-21,2	2,09
domingo	5,421	0,815	-18,5	2,09

El viernes concentra un 27 % más de tráfico que el promedio y el sábado un 21 % menos ($\chi^2 = 1313,2$, $p = 1{,}5 \times 10^{-280}$). La canasta, en cambio, es plana en los siete días: cambia cuánta gente entra, no qué compra. Ese perfil —creciente de lunes a viernes, bajo el fin de semana— corresponde a una tienda de entorno laboral o escolar, no residencial.

Ambos algoritmos reciben la misma matriz binaria y los mismos parámetros, así que la única variable es la implementación. De cada corrida se guarda una firma SHA-256 de sus itemsets frecuentes: coinciden en 8 de las 8 combinaciones comparables. Las otras 12 no se pueden comparar porque **apriori no terminó**: agotó la memoria en 36 de sus 60 corridas, todas las de soporte igual o menor a 0,001.

Soporte	max_len	apriori (s)	fp-growth (s)	Speedup
0,0002	sin límite	sin memoria	186,39	—
0,0005	sin límite	sin memoria	11,53	—
0,001	sin límite	sin memoria	2,98	—
0,002	sin límite	5,33	0,86	6,2×
0,005	sin límite	0,16	0,46	0,3×

4. Respuestas al taller

1. Reglas predecibles ($k = 1$). Las de mayor confianza son de insumo, no de consumo: caja de regalo

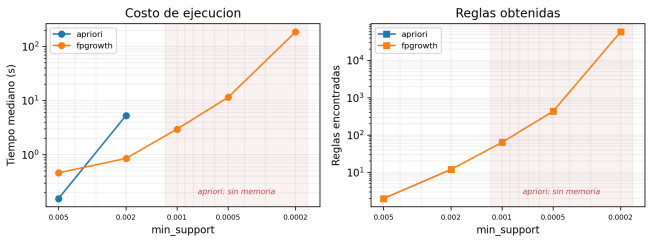


Figure 1: Tiempo y número de reglas según el soporte mínimo (escalas logarítmicas). Mismo resultado, distinto costo.

→ empaque (0,95). Entre productos de consumo, la predecible es empanada → jugo.

2. ¿Difieren los algoritmos? No en el resultado: donde ambos terminan, los itemsets son idénticos. Sí en costo, y de dos maneras. En tiempo, el orden se invierte según el soporte: a 0,005 apriori es casi tres veces *más rápido*, porque armar el FP-tree tiene un costo fijo que no se amortiza cuando hay poco que minar; a 0,002 fp-growth ya es seis veces más rápido. En memoria la diferencia es cualitativa: apriori materializa los candidatos de cada nivel, y con unos 500 ítems frecuentes eso son 125.000 pares contra 68.807 transacciones, de modo que el proceso muere. fp-growth no genera candidatos y completa el mismo caso en 11 segundos.

3. Efecto de los parámetros. El soporte mínimo gobierna todo:

Soporte	Facturas mín.	Itemsets	Reglas	Reglas ≥30	Lift máx.
0,005	344,0	86	2	2	1,5
0,002	138,0	276	12	12	1,58
0,001	69,0	493	64	64	14,27
0,0005	34,0	866	434	434	1720,17
0,0002	14,0	5,070	58,125	2,817	4914,79

Bajar de 0,0005 a 0,0002 multiplica las reglas por 134, pero solo una de cada veinte sobrevive al filtro de soporte absoluto. El soporte también decide qué algoritmo es viable: por debajo de 0,001, apriori deja de ser una opción en esta máquina. `max_len` acota el crecimiento limitando el tamaño de los itemsets, aunque no salva a apriori, porque el cuello está en los candidatos de nivel 2.

4. Reglas espurias. Sí, y con parámetros precisos: al soporte del análisis no aparece ninguna, porque el umbral ya garantiza 34 facturas por regla. Hay que bajar a 0,0002 (14 facturas) para obtenerlas, y surgen reglas de lift en los miles sostenidas por un puñado de facturas —globos y serpentina → toper de cumpleaños, lift 3.440 sobre 16 facturas—. El criterio aplicado contra ellas es el soporte *absoluto* (≥30 facturas), que no depende del tamaño del conjunto.

5. Reglas con $k > 1$. Existen, dominadas por combinaciones de armado de regalo. Hay que deduplicar por itemset: cinco productos generan más de veinte reglas con idénticos soporte y lift, que son la misma regla escrita de otra forma.

6. Probabilidad al azar. Si fueran independientes sería $P(A) \cdot P(B)$; el cociente entre el soporte observado y ese valor es exactamente el *lift*. Se contrastó además la tabla 2×2 con chi-cuadrado y Fisher, para afirmar la asociación con un p-valor.

7. Reglas interesantes. Las que unen soporte suficiente con lift sobre el azar son de comida rápida más bebida: empanada → jugo (411 facturas), papas → jugo, yogur → ponqué. Dos hallazgos fuera del patrón: la tienda presta servicio de papelería (fotocopia → impresiones, lift 65), y aparecen **sustitutos**, que el lift revela igual de bien —sándwich → empanada tiene lift 0,90—: un lift bajo 1 significa que los productos compiten por la misma compra.

8. Comportamiento del consumidor. Todo apunta a consumo inmediato: canasta de dos productos, ticket mediano de $5,189, 41 % de facturas de un solo ítem y reglas que unen un alimento con una bebida. El cliente no hace mercado, resuelve un hambre puntual, y que las reglas se mantengan estables entre días hábiles y fin de semana confirma que cambia el volumen de visitas, no la lógica de la compra.

5. Conclusiones y limitaciones

Elegir entre apriori y fp-growth no es cuestión de resultado sino de escala, y la frontera no es el tiempo sino la memoria: producen los mismos itemsets, pero por debajo de 0,001 apriori no llega a producirlos. A soporte alto, en cambio, apriori gana, así que la recomendación no es universal: depende del régimen, y este conjunto —canastas de dos productos— obliga al régimen donde fp-growth es la única opción. Ahí los soportes altos no devuelven nada y los muy bajos sobre todo ruido; el soporte absoluto resultó mejor filtro que el relativo. En lo descriptivo, la demanda se concentra en pocos productos de consumo inmediato y el día mueve el tráfico pero no la conducta, lo que sugiere ajustar inventario por día sin cambiar el surtido.

Tres limitaciones. No hay hora en los datos, así que el análisis intradía descansa en un supuesto declarado. Falta el DBF del viernes 5 de abril, por lo que ese día tiene una sola observación. Y la semana de abril no replica el efecto del día: su volumen cae entre 35 % y 91 % con un gradiente que sigue el orden de los días.